

Modèles d'apprentissage profond pour la classification d'images

Application à la classification des déchets ménagers et assimilés
à Moroni

SOIRFANE Abdallah Houmadi

Encadré par : **Dr. Abdoul-Hafar HALASSI BACAR**

UNIVERSITÉ DES COMORES
Faculté des Sciences et Techniques
Département de Mathématiques, Physique-Chimie & Informatique



soirfaneabdallahhoumadi863@gmail.com

Table des matières

- 1  Contexte & Motivation
- 2  Approche Proposée
 - Description de la base de données
 - Architecture du Modèle
 - Stratégie d'Entraînement
 - Résultats
- 3  Améliorations du Système
 - Amélioration de la Classification
 - Détection d'Anomalies
- 4  Conclusion
- 5  Bibliographie

Contexte & Motivation



CONTEXTE & MOTIVATION

Défis de la gestion des déchets aux Comores
et opportunités du Deep Learning

Gestion des Déchets : Un Enjeu Planétaire

De la production mondiale au cas concret de Moroni

Production Mondiale

- 2,24 milliards de tonnes de déchets (2023)
- **3,4 milliards** prévus d'ici 2050
- Pays riches : **34%** des déchets pour **16%** de la population

Gestion des Déchets : Un Enjeu Planétaire

De la production mondiale au cas concret de Moroni

Afrique Subsaharienne

- Croissance **rapide** des déchets
- **90%** en décharge sauvage
- **57%** de déchets organiques

Gestion des Déchets : Un Enjeu Planétaire

De la production mondiale au cas concret de Moroni

Cas de Moroni

- 0,27 kg/hab/jour
- 64% de déchets organiques
- Taux collecte : 30-35%
- Dépotoirs sauvages

Gestion des Déchets : Un Enjeu Planétaire

De la production mondiale au cas concret de Moroni

Impacts Majeurs

- Pollution des sols et eaux
- Émissions GES
- Risques sanitaires

Gestion des Déchets : Un Enjeu Planétaire

De la production mondiale au cas concret de Moroni

Solutions Existantes

- Réduction à la source
- Recyclage/valorisation
- Valorisation énergétique
- **Freins** : moyens, infrastructures

Gestion des Déchets : Un Enjeu Planétaire

De la production mondiale au cas concret de Moroni

✓ **Opportunité** : Les déchets peuvent devenir une **ressource**^{?, ?}

 **Notre objectif** : Utiliser l'**IA** pour **automatiser le tri** et améliorer la gestion locale

Approche Proposée



APPROCHE PROPOSÉE

Classification des déchets par apprentissage profond

- 1  Contexte & Motivation
- 2  Approche Proposée
 - Description de la base de données
 - Architecture du Modèle
 - Stratégie d'Entraînement
 - Résultats
- 3  Améliorations du Système
 - Amélioration de la Classification
 - Détection d'Anomalies
- 4  Conclusion
- 5  Bibliographie

Base de Données - Composition et Sources



Classes de Déchets

- 5 classes principales : Canette, Organique, Plastique, Textile, Verre
- Sélection basée sur les besoins locaux à Moroni
- Total : 12 138 images

Classe	Images	Pourcentage
Canette	1 792	14.8%
Organique	2 342	19.3%
Plastique	2 583	21.3%
Textile	2 665	22.0%
Verre	2 756	22.7%

Base de Données - Composition et Sources

Sources des Données

Combinaison de 4 bases open source + collecte locale

Source	Images
TrashNet	983
Waste Classification Data	3 738
Garbage Classification	5 275
Recyclable and Household Waste	1 350
Données locales (Moroni)	792

Spécificité

792 images collectées à Moroni pour adaptation au contexte

Base de Données - Composition et Sources

Validation Finale

Jeu de test indépendant réservé pour l'évaluation

Classe	Images de test
Canette	100
Organique	108
Plastique	170
Textile	77
Verre	82
Total	537

Base de Données - Composition et Sources

Protocole

- Données jamais vues pendant l'entraînement
- Évaluation réaliste des performances

Répartition des Données & Augmentation

Séparation Train/Test

- Répartition standard : 80% entraînement 20% test
- Application uniforme sur l'ensemble des données
- Préservation des proportions entre classes

Classe	Train (80%)	Test (20%)	Total
Canette	1 434	358	1 792
Organique	1 874	468	2 342
Plastique	2 066	517	2 583
Textile	2 132	533	2 665
Verre	2 205	551	2 756
Total	9 711	2 427	12 138

Répartition des Données & Augmentation

Augmentation des Données

Techniques appliquées pour améliorer la robustesse :

Technique	Paramètres
 Rotation	-30° à +30°
 Zoom aléatoire	0.8x à 1.2x
 Translation	±10%
 Retournement horizontal	50% probabilité
 Changement de luminosité	±20%
 Changement de saturation	±20%

Répartition des Données & Augmentation

Objectif

- Prévenir l'overfitting
- Améliorer la généralisation
- Robustesse aux variations réelles

- 1  Contexte & Motivation
- 2  Approche Proposée
 - Description de la base de données
 - **Architecture du Modèle**
 - Stratégie d'Entraînement
 - Résultats
- 3  Améliorations du Système
 - Amélioration de la Classification
 - Détection d'Anomalies
- 4  Conclusion
- 5  Bibliographie

 Architecture du Modèle Configuration de Base

- Entrée : images $240 \times 240 \times 3$ normalisées
- 5 blocs convolutifs avec BatchNorm + MaxPooling
- Activation ReLU : $\text{ReLU}(x) = \max(0, x)$
- Régularisation L2 sur les couches denses

Bloc	Filtres	Shape Sortie
Bloc 1	32	$120 \times 120 \times 32$
Bloc 2	64	$60 \times 60 \times 64$
Bloc 3	128	$30 \times 30 \times 128$
Bloc 4	128	$15 \times 15 \times 128$
Bloc 5	132	$7 \times 7 \times 132$

 Architecture du Modèle Couches Denses

- Flatten → 6468 neurones
- 5 couches denses avec décroissance progressive
- Sortie : Softmax pour 5 classes

Couche Dense	Neurones
Dense 1	512
Dense 2	256
Dense 3	128
Dense 4	100
Dense 5	64
Sortie	5

Architecture du Modèle

Variante Légère

- Remplacement Flatten → Global Average Pooling
- Réduction significative des paramètres
- Optimisé pour déploiement sur ressources limitées

- 1  Contexte & Motivation
- 2  Approche Proposée
 - Description de la base de données
 - Architecture du Modèle
 - **Stratégie d'Entraînement**
 - Résultats
- 3  Améliorations du Système
 - Amélioration de la Classification
 - Détection d'Anomalies
- 4  Conclusion
- 5  Bibliographie

Stratégie d'Entraînement

Configuration d'Entraînement

- Optimiseur : RMSprop
- Learning rate initial : 10^{-4}
- Fonction de perte : Sparse Categorical Cross-Entropy
- Batch size : 32
- Époques max : 200

Stratégie	Paramètres
Early Stopping	Patience = 30 (val_accuracy)
Reduce LR on Plateau	Patience = 15, Facteur = 0.2
Model Checkpoint	Sauvegarde meilleur val_accuracy

Stratégie d'Entraînement

Gestion du Déséquilibre

Pondération des classes dans la fonction de perte

Classe	Poids w_i	Effet
Canette	1.3365	Pénalité ++
Organique	1.0441	Pénalité +
Plastique	0.9296	Léger -
Textile	0.9204	Léger -
Verre	0.8835	Pénalité -

Calcul des poids

$$w_i = \frac{\text{moyenne}(n_c)}{n_i}$$

Plus n_i est petit, plus w_i est grand

Stratégie d'Entraînement

Techniques Avancées

- **RMSprop** : Adaptation dynamique du learning rate
- **ReduceLROnPlateau** : Réduction automatique quand val_loss stagne
- **Early Stopping** : Arrêt prématuré si pas d'amélioration
- **Model Checkpoint** : Sauvegarde des meilleurs poids

Objectifs

- Éviter le surapprentissage (overfitting)
- Assurer une convergence stable
- Optimiser les performances sur données de validation

Évaluation des Performances

Stratégie d'Évaluation

- Split standard : 80% entraînement 20% test
- Validation finale sur données locales réservées
- Simulation de scénario d'utilisation réelle

Ensemble	Données	Objectif
Entraînement	80%	Apprentissage des paramètres
Test	20%	Évaluation intermédiaire
Validation finale	Données locales	Test en conditions réelles

Évaluation des Performances

Métriques Principales

Évaluation multi-critères pour une vision complète

Métrique	Formule
Accuracy	$\frac{TP+TN}{TP+TN+FP+FN}$
Précision	$\frac{TP}{TP+FP}$
Rappel	$\frac{TP}{TP+FN}$

Avantages

- Prise en compte des déséquilibres de classes
- Vision multi-angle des performances
- Évaluation robuste et équilibrée

Évaluation des Performances

Interprétation des Métriques

- **Accuracy** : Performance globale
- **Précision** : Fiabilité des prédictions positives
- **Rappel** : Capacité à détecter toutes les instances
- **F1-score** : Compromis entre précision et rappel
- **mAP** : Performance moyenne par classe

Importance du Contexte

- Adaptation aux déséquilibres observés
- Validation sur données locales essentielles
- Métriques choisies pour le cas d'usage réel

- 1  Contexte & Motivation
- 2  Approche Proposée
 - Description de la base de données
 - Architecture du Modèle
 - Stratégie d'Entraînement
 - Résultats
- 3  Améliorations du Système
 - Amélioration de la Classification
 - Détection d'Anomalies
- 4  Conclusion
- 5  Bibliographie

Résultats


Comparaison des Deux Modèles

- **Modèle 1** : Architecture avec Flatten
- **Modèle 2** : Variante légère avec Global Average Pooling
- Objectif : Performance vs. Efficacité computationnelle

Caractéristique	Modèle 1	Modèle 2
Architecture	Flatten	Global Average Pooling
Paramètres	3.8M	0.56M
Temps entraînement	1j 14h 59m	1j 12h 17m
Époques	200	190

Résultats

Courbes d'Apprentissage



- Convergence stable pour les deux modèles
- Pas de sur-apprentissage (régularisation efficace)
- Modèle 2 : Arrêt précoce à 190 époques

Résultats

Performances par Classe

Classe	Modèle 1			Modèle 2		
	P	R	F1	P	R	F1
Canette	88.7	90.3	89.5	91.2	91.2	91.2
Organique	94.8	94.8	94.8	93.3	95.9	94.6
Plastique	89.1	87.9	88.5	91.0	87.7	89.3
Textile	96.6	97.1	96.9	94.5	96.8	95.6
Verre	94.1	93.7	93.9	93.8	92.5	93.1

Résultats

Matrices de Confusion

Confusion Matrix - Model 1

Can	90.27%	1.47%	5.01%	1.18%	2.06%
Organic	0.62%	94.81%	2.90%	0.62%	1.04%
Plastic	3.85%	2.23%	87.85%	2.02%	4.05%
Textile	1.26%	0.72%	0.72%	97.12%	0.18%
Glass	1.79%	0.90%	3.23%	0.36%	93.73%
	Can	Organic	Plastic	Textile	Glass

Confusion Matrix - Model 2

Can	91.15%	2.06%	2.65%	1.77%	2.36%
Organic	0.62%	95.85%	1.66%	1.24%	0.62%
Plastic	3.04%	1.82%	87.65%	2.83%	4.66%
Textile	0.54%	1.44%	1.26%	96.76%	0.00%
Glass	1.61%	1.61%	3.41%	0.90%	92.47%
	Can	Organic	Plastic	Textile	Glass

- Forte diagonale pour les deux modèles
- Confusions mineures Canette/Plastique
- Excellente détection Textile/Organique

Résultats

Synthèse des Performances

Métrique	Modèle 1	Modèle 2
Accuracy	93.04%	92.96%
Macro F1-score	92.70%	92.76%
Paramètres	3,806,525	562,493
Ratio légèreté	1×	6.8×

Conclusion

- Performances très similaires (92%)
- Modèle 2 : 7× plus léger avec performances équivalentes
- Choix optimal : Modèle 2 pour déploiement réel

Évaluation sur Données Locales

Problème de Généralisation

- Performance initiale décevante : F1 à 68% (sauf canette 80%)
- Écart entre données d'entraînement (idéalisées) et réalité terrain
- Images locales : résolution variable, objets multiples, cadrages complexes

Limites des Bases Publiques

- Images bien centrées, haute résolution
- Objet unique par image
- Conditions non représentatives du contexte réel

Évaluation sur Données Locales

Solution : Transfert Learning

- Réutilisation du modèle initial comme point de départ
- Entraînement des 3 dernières couches seulement
- 200 images/classe + 70% données locales pour l'affinage
- 30% données locales réservées pour l'évaluation finale

Élément	Description
Données d'affinage	70% données locales
Données de test	30% données locales
Renfort	20 images/classe des tests initiaux
Prétraitement	Identique à l'entraînement initial

Évaluation sur Données Locales

Courbes d'Apprentissage après Transfert



- Convergence rapide grâce au transfert learning
- Adaptation efficace aux spécificités locales
- Stabilité de l'apprentissage

Évaluation sur Données Locales

Résultats après Transfert Learning

Classe	Modèle 1 F1	Modèle 2 F1
Canette	91.6%	93.8%
Organique	88.6%	89.2%
Plastique	85.7%	81.8%
Textile	74.1%	70.4%
Verre	90.5%	88.4%
Accuracy	86.5%	85.3%
Macro F1	86.1%	84.7%

Évaluation sur Données Locales

Matrices de Confusion - Données Locales

Confusion Matrix - Model 1

Can	95.00%	2.50%	2.50%	0.00%	0.00%
Organic	5.71%	88.57%	0.00%	2.86%	2.86%
Plastic	4.17%	0.00%	81.25%	12.50%	2.08%
Textile	0.00%	11.54%	11.54%	76.92%	0.00%
Glass	4.76%	0.00%	0.00%	4.76%	90.48%
	Can	Organic	Plastic	Textile	Glass


Confusion Matrix - Model 2

Can	95.00%	0.00%	0.00%	2.50%	2.50%
Organic	0.00%	94.29%	2.86%	0.00%	2.86%
Plastic	4.17%	4.17%	75.00%	14.58%	2.08%
Textile	3.85%	15.38%	7.69%	73.08%	0.00%
Glass	0.00%	0.00%	4.76%	4.76%	90.48%
	Can	Organic	Plastic	Textile	Glass

- Amélioration significative après transfert learning
- Réduction des erreurs de classification
- Meilleure adaptation au contexte local

Évaluation sur Données Locales

Comparaison Avant/Après Transfert



- Gain important en précision de classification
- Réduction du taux d'erreur
- Validation de l'approche par transfert learning

Améliorations du Système



AMÉLIORATIONS DU SYSTÈME

Optimisation et perfectionnement de la solution

- 1  Contexte & Motivation
- 2  Approche Proposée
 - Description de la base de données
 - Architecture du Modèle
 - Stratégie d'Entraînement
 - Résultats
- 3  Améliorations du Système
 - Amélioration de la Classification
 - Détection d'Anomalies
- 4  Conclusion
- 5  Bibliographie

Amélioration de la Classification

Constat et Défis

- Essor des méthodes de classification pour le tri automatisé
- Résultats satisfaisants mais limites en contexte réel
- Problèmes de généralisation sur données variées
- Erreurs face à des situations complexes ou nouvelles

Objectif

- Analyser les limitations identifiées
- Proposer des stratégies d'amélioration
- Renforcer précision et adaptabilité en conditions réelles

Amélioration de la Classification

Facteurs Limitants

- **Faible volume** de données locales disponibles
- **Déséquilibre persistant** avec données publiques
- Modèle influencé par les caractéristiques dominantes

Stratégie d'Amélioration

- **Équilibre optimal** entre données locales et publiques
- Données locales : adaptation au contexte réel
- Données publiques : diversité et stabilité
- Recherche de complémentarité pour une robustesse durable

- 1  Contexte & Motivation
- 2  Approche Proposée
 - Description de la base de données
 - Architecture du Modèle
 - Stratégie d'Entraînement
 - Résultats
- 3  Améliorations du Système
 - Amélioration de la Classification
 - Détection d'Anomalies
- 4  Conclusion
- 5  Bibliographie

Détection d'Anomalies

Problème Identifié

- Modèles de classification limités aux classes connues
- Fausses prédictions inévitables pour déchets inconnus
- Impact critique sur les projets de valorisation (biogaz, électricité)
- Risque environnemental et économique

Solution Proposée

Intégration de mécanismes de détection d'anomalies avant classification

Détection d'Anomalies

Trois Approches Explorées

- **Confiance du modèle** : Seuil sur les probabilités de prédiction
- **Autoencodeur** : Détection basée sur l'erreur de reconstruction
- **Discriminateur GAN** : Distinction données connues/inconnues



Base de Données d'Évaluation

- 4 000 images de test (2 000 connues + 2 000 inconnues)
- Données inconnues : batteries, couches, cartons, autres déchets
- Simulation de contexte réaliste avec nouvelles catégories

Détection par Seuil de Confiance

Principe de la Méthode

- Analyse des probabilités de prédiction du modèle
- Rejet si probabilité maximale $<$ seuil fixé
- Acceptation si probabilité maximale $\geq$ seuil
- 20 valeurs testées entre 50% et 100%



Détection par Seuil de Confiance

Résultats Expérimentaux

Modèle	Meilleur seuil	Exactitude
Sans TL (Flatten)	0.973	76.79%
Sans TL (AvgPooling)	0.999	75.89%
Avec TL (Flatten)	0.973	72.27%
Avec TL (AvgPooling)	0.973	72.64%


Analyse

- Courbe montre l'évolution performance/seuil
- Meilleurs résultats sans transfert learning
- Seuils optimaux entre 0.973 et 0.999
- Performance limitée à $\sim 77\%$ maximum

Détection par Autoencodeur Variationnel (β -VAE)

Principe et Architecture


- Autoencodeur entraîné sur données "normales"
- Détection par erreur de reconstruction
- Architecture β -VAE résiduelle ($\beta = 0.001$)
- Espace latent : 128 dimensions



Courbe d'apprentissage montrant le surapprentissage

Détection par Autoencodeur Variationnel (β -VAE)



Exemples de Reconstruction



Haut : entraînement - Bas : test (reconstructions imprécises)

Détection par Autoencodeur Variationnel (β -VAE)

Optimisation du Seuil




Évolution des métriques en fonction du seuil (optimal : 0.01607)

Détection par Autoencodeur Variationnel (β -VAE)

Résultats et Performance


Classe	Précision	Rappel	F1-score
Normal	75.7%	84.4%	79.8%
Anormal	82.4%	73.0%	77.4%



Détection par Réseaux Antagonistes GANs

Principe et Architecture


- Deux réseaux : Générateur (crée des images) vs Discriminateur (détecte les fausses)
- Objectif : Exploiter le discriminateur pour détecter les anomalies
- Images taille réduite : $64 \times 64 \times 3$ pour contraintes matérielles



Évolution instable des pertes - Pas de convergence

Détection par Réseaux Antagonistes GANs

Résultats et Limitations



Images générées de mauvaise qualité - Formes floues

Détection par Réseaux Antagonistes GANs

Échec de l'Entraînement

- Arrêt après 58 époques (pas d'amélioration)
- Discriminateur trop dominant
- Impossible de tester la détection d'anomalies
- Approche prometteuse mais nécessite plus de ressources

Conclusion



CONCLUSION

Pour donner des éléments de conclusion,
ce travail montre une belle opportunité d'automatiser
le tri des déchets avec des modèles de Deep Learning

Conclusion



Mais pour y arriver...

il nous reste encore un bout de chemin à parcourir



Remerciements

**Je vous remercie du fond
du cœur**

pour votre attention et votre présence

Bibliographie